

公开基准复现试点

结论与边界

DevOrbit 已冻结并真实复现 1 个 SWE-bench dev validation pilot：`sqlfluff__sqlfluff-884`。固定 base commit 应用官方 test patch 后，唯一 FAIL_TO_PASS 精确失败于 `assert raw_seg.is_whitespace`；evaluator-only 金修复验证目标测试 1/1、所在 ANSI 测试文件 43/43 通过。

这不是 DevOrbit 修复结果、正式 test split、公开基准分数或排名结论。正式计分 manifest 仍为 0 案例，报告状态仍为 `not_run`。pilot 只证明来源冻结、环境构建、缺陷复现、gold 隔离和证据校验链路已经打通。

冻结来源

字段	值
数据集	princeton-nlp/SWE-bench dev, 225 cases
数据快照	<code>e48e2bd1e9fec</code> <code>d5bbd641e9414ac59da9f2e69f6</code>
Parquet	1,382,594 bytes；SHA-256 <code>d758d545...47fc41b</code>
案例	<code>sqlfluff__sqlfluff-884</code>
上游	<code>sqlfluff/sqlfluff</code> , MIT
PR / Issue	PR #884, 正文 resolves Issue #847
Base	<code>c0bad78f3fa9549591738c77f869724f721e6830</code>
PR Head / Merge	<code>5dcf226...</code> / <code>ed4e056...</code>
Test patch	SHA-256 <code>3e799cc...de50</code>
Gold patch	evaluator-only；仅保存 SHA-256 <code>f292031...fe2</code>

固定数据卡没有显式声明 dataset license；因此仓库不再分发 Parquet，只记录快照、LFS 对象摘要、大小和案例派生证据。SWE-bench 软件仓库当前 LICENSE 为 MIT，上游 SQLFluff base commit 的 LICENSE 也已独立核验为 MIT。

环境与复现

可审计环境为 Ubuntu 22.04、Python 3.10.12、SQLFluff 0.4.1、pytest 6.2.5、packaging 21.3，其余版本见 `evaluation/public-pilot/sqlfluff__sqlfluff-884/requirements.lock`。SQLFluff 0.4.1 分类器只列到 Python 3.9，因此 Python 3.10.12 是已披露偏差；它已在两个干净依赖目录中复现完全相同的业务断言，不是导入、安装或 collection 失败。

离线核验仓库证据：

```
npm run validate-public-pilot
```

联网下载固定源码、核验 archive/LICENSE 摘要、重建依赖并复现 baseline：

```
npm run reproduce-public-pilot
```

重放脚本只访问 base 源码和公开 test patch，不读取 gold patch。正式多方法评测仍须扩充到预注册的 repository-grouped validation/test 集，冻结 Agent 配置后才运行 test，并按 Wilson、paired bootstrap 和 McNemar 协议报告。