

评分证据索引

评审问题	可验证证据	复核命令
是否真的以 AgentTeams 为基点	官方 v1.2.2 本地 Team Active, Leader Ready、7/7 Worker Ready；另有 141 项契约与可移植部署编排	npm run validate-agentteams-runtime；npm run validate-agentteams && npm run deploy-agentteams-smoke
多 Agent 是否有真实边界	7 个 QwenPaw Worker、31 条 TeamHarness 生命周期、7 条 Worker Matrix 事件、16 次身份化 MCP 调用	reports/agentteams-runtime.json；docs/AgentTeams本地运行验证.md
Skill 是否可复用和可分发	7 个 Skill 包、I/O/失败/安全/版本、官方 SLS Skill 锁定；SemVer+sha256 注册表与生命周期	skills/、worker-packages/dist/、docs/Skill清单.md、npm run write-skills-registry → reports/skills-registry.json
Skill 调用是否可溯源	每次运行 trace 记录 skillVersion + skillDigest，结果可定位到 Skill 版本	npm run validate（trace records skill version and digest）；reports/skills-registry.json
工具是否通过稳定契约调用	MCP 2025-06-18 / 2025-11-25、14 Tool、会话版本绑定、运行时输入/输出 Schema、幂等	npm run mcp-smoke
Fixture 能否替换为外部平台	六类 HTTP Provider、OpenAPI 3.1、17 请求/两次安全重试/15 MCP 审计	npm run validate-adapters && npm run adapter-smoke；docs/Adapter生产契约.md
安全是否由系统强制	Agent×Tool allowlist、签名审批、Case/Action scope、过期、路径防护	npm run evaluate-security；docs/威胁模型.md
生产入口是否受控	控制面 Bearer、外部模式禁用一键批准、MCP 鉴权、1 MiB 限制、静态白名单	npm run api-security-smoke
容器是否满足最小权限	UID 10001、只读根、tmpfs、cap-drop ALL、no-new-privileges、完整审批闭环	npm run container-smoke；reports/container-smoke.json
Agent 状态是否闭环持久	Case State+证据链快照原子落盘；崩溃重启后审批续跑同 case/trace，证据链连续校验；终态自动清理	src/runtime/state-store.test.js（5 项）；npm run api-smoke
上下文与记忆是否受治理	四层上下文区分、版本/权限/过期清理、租户硬过滤防串扰、陈旧版本召回阻断、冲突降级	config/policy.yaml context_governance；src/knowledge/episode-store.test.js（3 项治理测试）
修复是否真实验证	隔离样例仓 3 failed → 4 passed、测试制品摘要	npm test；reports/runs/happy-path.json
场景是否可复制迁移	结算→库存第二类场景迁移：机制零改动，双域 3 失败→4 通过闭环，Worker×Skill/状态/工具序列完全一致	npm run scenario-migration；reports/scenario-migration.json；docs/场景迁移复制路径.md
故障下是否可靠降级	6 类故障注入：返工熔断/模型 429 重试/500 fail-closed 不泄露密钥/工具错误审计/DB 门禁/端点不可达	npm run fault-drill；reports/fault-drill.json
失败分支是否可回放	低置信停止、测试失败、审批拒绝、灰度回滚、坏输入隔离	npm run evaluate；reports/evaluation.md
各门禁是否有独立贡献	7 组对照/消融；关闭核心门禁后准确/安全下降	npm run evaluate-benchmark；reports/benchmark.md
是否有可复现的公开基准协议	V0.9.6 正式计分：同冻结 30 案例 devorbit 闭环 3/30（10%）、可应用率 56%、single-agent 0/30；Run 1–11 全留痕	npm run public-benchmark；reports/public-benchmark.json；reports/model-ablation.md
真实模型能否被测试反馈约束	本地 qwen3:8b Run 1–11 全披露；Run 7 旧门禁通过后被新增兼容性反例推翻，Run 11 在正确工厂锚点仍被增强门禁拒绝；39/39 失败证据校验	npm run validate-public-model-pilot-v11；reports/public-model-pilot-v11.json；docs/公开基准复现试点.md
新仓库上是否 fail closed	预先筛选并冻结 pydicom__pydicom-965；单次补丁产生重复 exact-edit，契约在评估前拒绝；无换题、无重试、无成功率声称；26/26 证据校验	npm run validate-independent-model-pilot；reports/independent-model-pilot.json；evaluation/independent-model-pilot.manifest.json

评审问题	可验证证据	复核命令
是否有真实平台连接器边界	GitHub/Git/Jenkins/Argo 闭环；FD 锚定路径防护；JSON Patch + generation gate；外部写持久幂等、未知结果 fail closed/带证据对账；hardened native runner	<code>npm run native-platform-smoke</code> ； <code>npm run native-runner-smoke</code> ； <code>npm run reconcile-idempotency -- ...</code> ；docs/原生平台连接器.md；两份 native 报告
RAG 是否可评估	4 个不同查询 Top-1/引用评测；无 RAG 消融引用率归零	<code>npm run evaluate-rag && npm run evaluate-benchmark</code>
可观测是否能进入标准后端	OTLP JSON 形态的 Agent/Tool Span、语义属性和 5 类 Metrics	<code>npm run export-otel</code> ；reports/otel-happy-path.json
提交物是否一致且可复现	代码包、PDF/PPTX、视频、摘要和发布审计	<code>npm run finalize-submission</code>

7 个 Golden Cases、RAG、对照/消融和安全指标均为团队构造仿真，只证明当前工作流、协议和策略行为。AgentTeams 证据是真实官方软件的本地运行，但 DevOrbit 工具仍基于 Fixture；SWE-bench 问题调优链和跨仓单次验证均以拒绝终止，后者只是独立负例，不是 benchmark 成功率或正式分数。上述证据都不外推为云账号、厂商平台、生产集群或生产收益。