

评分证据索引

评审问题	可验证证据	复核命令
是否真的以 AgentTeams 为基点	8 Worker/1 Team CR、7 Worker ZIP、140 项契约与两阶段部署编排	<code>npm run validate-agentteams && npm run deploy-agentteams-smoke</code>
多 Agent 是否有真实边界	7 个独立 Worker、版本化 Case State、结构化消息、父子 Span	<code>npm test ; reports/runs/happy-path.json</code>
Skill 是否可复用和可分发	7 个 Skill 包、I/O/失败/安全/版本、官方 SLS Skill 锁定	<code>skills/、worker-packages/dist/、docs/Skill清单.md</code>
工具是否通过稳定契约调用	MCP 2025-06-18、10 Tool、运行时输入/输出 Schema、幂等	<code>npm run mcp-smoke</code>
Fixture 能否替换为外部平台	六类 HTTP Provider、OpenAPI 3.1、17 请求/两次安全重试/15 MCP 审计	<code>npm run validate-adapters && npm run adapter-smoke ; docs/Adapter生产契约.md</code>
安全是否由系统强制	Agent×Tool allowlist、签名审批、Case/Action scope、过期、路径防护	<code>npm run evaluate-security ; docs/威胁模型.md</code>
生产入口是否受控	控制面 Bearer、外部模式禁用一键批准、MCP 鉴权、1 MiB 限制、静态白名单	<code>npm run api-security-smoke</code>
容器是否满足最小权限	UID 10001、只读根、tmpfs、cap-drop ALL、no-new-privileges、完整审批闭环	<code>npm run container-smoke ; reports/container-smoke.json</code>
修复是否真实验证	隔离样例仓 3 failed → 4 passed、测试制品摘要	<code>npm test ; reports/runs/happy-path.json</code>
失败分支是否可回放	低置信停止、测试失败、审批拒绝、灰度回滚、坏输入隔离	<code>npm run evaluate ; reports/evaluation.md</code>
各门禁是否有独立贡献	7 组对照/消融；关闭核心门禁后准确/安全下降	<code>npm run evaluate-benchmark ; reports/benchmark.md</code>
是否有可复现的公开基准协议	正式计分 0 案例/0 分数；另有 1 个 SWE-bench dev validation pilot 已冻结并复现真实失败，gold evaluator-only 验证 1/1 + 43/43	<code>npm run public-benchmark ; npm run validate-public-pilot ; npm run reproduce-public-pilot ; docs/公开基准协议.md ; evaluation/public-benchmark-pilot.manifest.json</code>
是否有真实平台连接器边界	GitHub/Git/Jenkins/Argo 闭环；FD 锚定路径防护；JSON Patch + generation gate；外部写持久幂等、未知结果 fail closed/带证据对账；hardened native runner	<code>npm run native-platform-smoke ; npm run native-runner-smoke ; npm run reconcile-idempotency -- ... ; docs/原生平台连接器.md ; 两份 native 报告</code>
RAG 是否可评估	4 个不同查询 Top-1/引用评测；无 RAG 消融引用率归零	<code>npm run evaluate-rag && npm run evaluate-benchmark</code>
可观测是否能进入标准后端	OTLP JSON 形态的 Agent/Tool Span、语义属性和 5 类 Metrics	<code>npm run export-otel ; reports/otel-happy-path.json</code>
提交物是否一致且可复现	代码包、PDF/PPTX、视频、摘要和发布审计	<code>npm run finalize-submission</code>

7 个 Golden Cases、RAG、对照/消融和安全指标均为团队构造仿真，只证明当前 workflow、协议和策略行为。SWE-bench validation pilot 是真实公开缺陷复现，但没有运行 DevOrbit、没有生成分数；两类证据都不外推为生产收益。